

A I 伦理治理与前沿

介绍公平性、隐私、安全、可解释性、治理框架以及前沿发展趋势，帮助学习者形成负责任的 A I 观。

模块名称：A I 伦理治理与前沿

模块简介

人工智能越强大，越需要从社会、法律和工程多个层面考虑其影响。本模块帮助学习者建立“负责任使用 A I ”的基本意识。

学习目标

- 1 . 理解公平性、隐私、安全和可解释性等关键议题。
- 2 . 认识数据偏见和模型偏差可能造成的社会后果。
- 3 . 了解 A I 治理与对齐的基本思路。
- 4 . 关注当前 A I 前沿趋势与未来挑战。

伦理议题

如果训练数据本身带有偏见，模型就可能放大这种偏差，影响招聘、金融、医疗和教育等敏感场景。隐私问题则涉及个人数据收集、存储和使用边界。

安全与可解释性

A I

系统可能出现幻觉、越权、误判或被攻击等问题。可解释性有助于人类理解模型为何给出某个结果，特别是在高

治理与对齐

治理不仅是法律约束，也包括产品流程、审核机制、权限控制和人机协同。对齐强调让模型目标、系统行为和人类价值更一致，避免输出虽然“看起来合理”却不符合真实需求。

前沿趋势

多模态模型、智能体系统、检索增强生成、可控生成和更强的推理能力是当前热点。同时，算力成本、能源消耗、版权争议和安全治理也会长期存在。

课堂活动建议

可以选取一个 A I

应用案例，让学生从“技术效果、伦理风险、治理措施”三个角度进行讨论，训练综合分析能力。

测评重点

公平性、隐私、安全、可解释性概念；数据偏见影响；治理与对齐思路；前沿趋势和风险。