

A I G C 与生成模型

关键词：A I G C , G A N , 扩散模型 , S t a b l e D i f f u s i o n , C o n t r o l N e t

A I G C 与生成模型

关键词：A I G C , G A N , 扩散模型 , S t a b l e D i f f u s i o n , C o n t r o l N e t

生成式 A I 的发展脉络

A I G C (A I G e n e r a t e d C o n t e n t , 人工智能生成内容)指利用人工智能自动生成文本、图像、音频、视频、代码等技术产物。其发展脉络大致可分为三个阶段

- 1 . 规则与模板阶段 (2 0 1 0 前) : 基于模板的文本生成、马尔可夫链、隐马尔可夫模型语音合成
- 2 . 深度生成模型阶段 (2 0 1 4 - 2 0 2 0) : G A N 、 V A E 、 N o r m a l i z i n g F l o w 、自回归模型相继出现,能生成逼真图像与语音
- 3 . 大规模预训练阶段 (2 0 2 0 至今) : 扩散模型在图像生成取得突破; T r a n s f o r m e r 类大模型 (G e n e r a t i v e A d v e r s a r i a l N e t w o r k , S o r a) 实现跨模态高质量生成, A I G C 进入大规模商用

A I G C 已成为内容创作的关键生产力工具,覆盖文生图、文生视频、文生音乐、文生代码等众多方向,正在重塑创意、生产与分发流程

G A N 系列

G A N 基本原理

G A N (G e n e r a t i v e A d v e r s a r i a l N e t w o r k , 生成对抗网络) 由 I a n J o y n t o n 于 2 0 1 4 年提出,核心思想是通过生成器 (G e n e r a t o r) 与判别器 (D i s c r i m i n a t o r) 的博弈学习生成逼真数据

G A N 训练循环简化伪代码

```
import torch
import torch.nn as nn
import torch.nn.functional as F

def train_gan(generator, discriminator, dataloader, device):
    bce = nn.BCEWithLogitsLoss()
    for epoch in range(epochs):
        for real_imgs in dataloader:
            batchsize = real_imgs.size(0)
            real_labels = torch.ones(batchsize, 1)
```

```

fake_labels = torch.zeros(batchsize, 1)

# - - - 训练判别器 - - -
z = torch.randn(batchsize, zdim)
fake_imgs = generator(z).detach()
d_loss = (bce(discriminator(real_imgs), real_labels) +
bce(discriminator(fake_imgs), fake_labels)) / 2
optimizer_d.zero_grad(); d_loss.backward(); optimizer_d.step()

# - - - 训练生成器 - - -
z = torch.randn(batchsize, zdim)
fake_imgs = generator(z)
g_loss = bce(discriminator(fake_imgs), real_labels)
optimizer_g.zero_grad(); g_loss.backward(); optimizer_g.step()

```

DCGAN

DCGAN (Deep Convolutional GAN) 将卷积网络引入 GAN，使用转置卷积进行上采样、批归一化稳定训练，首次实现高质量图像生成。

StyleGAN

StyleGAN 由 NVIDIA 提出，引入 风格映射网络 (Mapping Network) 与 Normalization)，将潜变量分离为不同层级的风格，实现细粒度属性控制（如姿态、发型、肤色），进一步改善伪影与纹理粘连问题，是人脸生成的工业标准。

CycleGAN

CycleGAN 解决无配对数据的图像到图像翻译问题，通过 循环一致性损失 (Cycle Consistency Loss) 保证内容保留，实现马↔斑马、夏↔冬、莫奈画作↔照片等风格转换。

CycleGAN 循环一致性损失

```

def cycle_loss(GF, GB, x, y, lambdacyc=10.0):
    reconstructed_x = GB(GF(x))
    reconstructed_y = GF(GB(y))
    return lambdacyc * (F.l1_loss(reconstructed_x, x) +
F.l1_loss(reconstructed_y, y))

```

GAN 系列对比

模型 关键创新 主要应用 局限

GAN 对抗训练 图像生成 训练不稳定、模式崩溃

DCGAN 卷积架构 自然图像 分辨率有限

StyleGAN 风格解耦 人脸编辑 训练数据需求大

CycleGAN 循环一致性 风格迁移 难处理大几何变化

VAE 与扩散模型

VAE (变分自编码器)

VAE (Variational Autoencoder)

通过变分推断学习数据的潜在分布。编码器输出潜变量的均值与方差，解码器从采样的潜变量重构输入。VAE 优化 ELBO (证据下界)，训练稳定、可显式建模概率分布，但生成图像常偏模糊。

扩散模型 (Diffusion Models)

扩散模型 的核心思想包含两个过程：

- 前向过程 (Forward Process)：逐步向数据添加高斯噪声，最终变为纯噪声
- 反向过程 (Reverse Process)：学习一个神经网络逆向去噪，从噪声还原出数据

扩散模型理论严谨、训练稳定、生成质量超越 GAN，是当前主流的生成范式。DDPM (Denoising Probabilistic Models) 是其奠基性工作。

DDPM 训练与采样伪代码

```
import torch
```

```
class DDPM:
```

```
def __init__(self, T=1000, betastart=1e-4, betaend=0.01):
```

```
    self.T = T
```

```
    self.betas = torch.linspace(betastart, betaend, T-1)
```

```
    self.alphas = 1 - self.betas
```

```
    self.alphabars = torch.cumprod(self.alphas, dim=0)
```

```
def qsample(self, x0, t, noise=None):
```

```
    """ 前向加噪 """
```

```

if noise is None:
    noise = torch.randnlike(x0)
    sqrttab = self.alphabars[t].sqrt().view(-1, 1, 1, 1)
    sqrt1mab = (1 - self.alphabars[t]).sqrt().view(-1, 1, 1, 1)
    return sqrttab * x0 + sqrt1mab * noise, noise

def trainstep(self, model, x0):
    t = torch.randint(0, self.T, (x0.size(0),))
    xt, noise = self.qsample(x0, t)
    prednoise = model(xt, t)
    return F.mse_loss(prednoise, noise)

@torch.no_grad()
def sample(self, model, shape):
    x = torch.randn(shape)
    for t in reversed(range(self.T)):
        z = torch.randn(shape) if t > 0 else 0
        betat = self.betas[t]
        mean = (1 / self.alphas[t].sqrt()) * (x - (betat / self.alphas[t]) * torch.tensor([t]))
        x = mean + betat.sqrt() * z
    return x

```

Stable Diffusion 架构解析

Stable Diffusion (SD) 由 Stability AI 与 CompVis 团队提出。其核心思想是 Latent Diffusion：不在像素空间做扩散，而在 VAE 压缩后的潜在空间进行，大幅降低计算成本。

架构组成：

1. VAE 编码器：将图像压缩到 $4 \times 64 \times 64$ 的潜在表示
2. U-Net：在潜在空间进行迭代去噪，输入含噪声的 latent、时间步与文本条件
3. 文本编码器 (CLIP Text Encoder)：将 prompt 编码为条件向量，通过 CLIP 模型
4. VAE 解码器：将去噪后的 latent 解码回像素图像

Stable Diffusion 推理流程简化伪代码

```

def stable_diffusion_inference(prompt, unet, vae, t_scheduler):
    # 1. 文本编码
    text_emb = text_encoder(prompt) # [1, 77, 768]
    # 2. 随机初始化 latent
    latent = torch.randn(1, 4, 64, 64)
    # 3. 迭代去噪
    scheduler.set_timesteps(num_steps)
    for t in scheduler.timesteps:
        noise_pred = unet(latent, t, encoder_hidden_states=text_emb)
        latent = scheduler.step(noise_pred, t, latent).pred_noise
    # 4. 解码回像素
    image = vae.decode(latent / 0.18215)
    return image

```

文本到图像生成流程

完整的文生图系统通常包含：

1. Prompt 解析与增强：用户输入 → 标准化提示词（可叠加风格词、负面提示）
2. 文本编码：CLIP / T5 将提示编码为条件向量
3. 潜在扩散采样：U-Net 去噪，CFG (Classifier-Free Guidance) 引导
4. 高分辨率放大：Latent Upscaling 或 Super-Resolution 提升分辨率
5. 后处理：面部修复 (CodeFormer)、超分、安全过滤

Classifier-Free Guidance 公式

```

def cfg_noise_pred(unet, latent, t, text_emb, uncond_emb):
    noise_uncond = unet(latent, t, uncond_emb)
    noise_cond = unet(latent, t, text_emb)
    return noise_uncond + guidance_scale * (noise_cond - noise_uncond)

```

条件控制 (ControlNet、IP-Adapter)

ControlNet

ControlNet 由 Lvmin Zhang 提出，通过为 U-Net 添加一个可训练的副本（带零卷积连接），引入结构化条件（如边缘、深度图、骨架、法线图），实现对生成图

ControlNet 简化结构

```
class ControlNet(nn.Module):
    def __init__(self, unet):
        super().__init__()
        self.unetcopy = copy.deepcopy(unet) # 可训练副本
        self.zeroconv = nn.Conv2d(320, 320, 1)
        # zeroconv 初始权重为 0, 保证训练初始等价于原 SD
        nn.init.zeros(self.zeroconv.weight)
        nn.init.zeros(self.zeroconv.bias)

    def forward(self, latent, t, textemb, controlimage):
        # 在副本中注入条件图特征
        return self.zeroconv(self.unetcopy(latent, t, textemb, controlimage))
```

常见 ControlNet 类型: Canny 边缘、HED 边缘、OpenPose 骨架、Depth 分割图。

IP-Adapter

IP-Adapter 实现图像 prompt 的轻量化注入, 将参考图像的视觉特征作为额外的 Cross-Attention 输入, 支持风格迁移、角色一致性生成, 参数量小、即插即用。

视频生成

Sora

Sora 由 OpenAI 于 2024 年发布, 基于 DiT (Diffusion Transformer) 架构, 进行扩散建模。Sora 能生成长达 1 分钟的高保真视频, 展现出对物理世界初步的模拟能力, 被视为 "世界模拟器" 的雏形。

Kling (可灵)

Kling

是快手推出的国产视频生成模型, 在长视频、复杂运动、物理一致性方面表现优异, 支持文生视频、图生视频、图生图。

Runway Gen-3

Runway Gen-3 Alpha 在电影级画面质量、镜头控制方面表现突出, 是商业视频生成的代表。

视频生成对比：

模型 架构 最大时长 物理一致性 主要优势

Sora DiT ~60s 较强 世界模拟潜力

Kling Diffusion+ ~2min 强 长视频、运动自然

Runway Gen-3 DiT 变体 ~10s 中 画质电影感

Pika Diffusion ~3s 中 编辑能力强

音乐与语音生成

- 音乐生成：Suno、Udio 实现端到端的歌词+旋律+人声合成；MusicGen、Jasco Transformer 与音频 codec
- 语音克隆与 TTS：VITS、NaturalSpeech、Bark、ChatTTS 等实现高自然度
- 音频 codec：EnCodec、SoundStream 将音频离散化为 token，支撑音频生成

AI GC 版权与伦理

AI GC 高速发展同时带来多重伦理挑战：

1. 版权争议：训练数据使用受版权保护作品的合法性（如 Getty Images 起诉 Stable Diffusion）
2. 深度伪造（Deepfake）：换脸、语音克隆用于诈骗、诽谤、政治操纵
3. 身份与肖像权：未经授权使用名人或普通人的形象
4. 偏见与歧视：训练数据偏见被放大，生成刻板印象
5. 就业冲击：插画师、配音、翻译等岗位受冲击
6. 内容标识：监管要求 AI 生成内容显式或隐式标识

应对策略包括：合规训练数据、内容水印（如 SynthID）、深度伪造检测、AI GC 标识法规（中国《深度合成管理规定》要求显著标识）、创作者收益分享机制等。

总结

AI GC 已从研究原型发展为重要生产力。技术脉络上，GAN 主导了 2014-2020 的图像生成，后全面超越 GAN，Stable Diffusion 推动开源生态，ControlNet 等条件控制模型等视频生成模型展示了迈向 "世界模型" 的可能。未来 AI GC 将向更高保真、更强可控、多模态统一方向发展，同时需要建立与之匹配的版权、伦理、安全治理体系，让生成式 AI 真正服务于社会福祉。