

R A G 检索增强生成系统设计

从问题重写、切块、召回、重排到引用展示，完整介绍 R A G 链路。

R A G

的核心思想是先从外部知识库中找到相关内容，再把检索结果注入生成上下文，让回答更可控、更贴近资料来源。

R A G

流程通常包括问题理解与重写、文档切块、索引构建、召回、重排、上下文拼接、答案生成和引用展示。切块即

R A G 系统输出的不只是答案，还包括来源和限制说明。