

机器学习基础

介绍数据、特征、训练流程、泛化能力与偏差方差，为后续监督学习和深度学习打基础。

模块名称：机器学习基础

模块简介

机器学习研究如何让模型从数据中学习规律，并在新样本上做出预测或判断。本模块是进入监督学习、无监督学习与深度学习之前必须掌握的共通知识。

学习目标

1. 理解训练集、验证集、测试集的作用。
2. 掌握特征、标签、模型、损失函数等基础概念。
3. 理解欠拟合、过拟合与泛化能力。
4. 认识偏差和方差之间的权衡关系。

数据与特征

机器学习的输入通常是特征，输出可以是类别、数值或结构化结果。高质量特征能显著提升模型效果。即使在深度学习时代，数据清洗、标注质量和特征理解仍然非常重要。

训练流程

一般流程包括数据收集、清洗、划分数据集、特征处理、模型训练、超参数调优、验证评估和测试部署。训练集用于学习参数，验证集用于调参，测试集用于最终无偏评估。

泛化与过拟合

过拟合指模型在训练集表现很好，但在新数据上表现差；欠拟合则是模型能力不足，连训练集都学不好。泛化能力表示模型面对未见样本时仍能保持稳定表现。

偏差与方差

高偏差通常意味着模型过于简单，高方差通常意味着模型对训练数据过于敏感。工程上常通过增加数据、正则化、交叉验证或更合理的模型复杂度来平衡两者。

课堂活动建议

可以用一个简单的房价预测案例，分别展示特征设计不足、模型过复杂、数据量过小对结果的影响，让学生理解为什么“数据、模型、评估”必须一起看。

测评重点

训练集 / 验证集 / 测试集的区别；过拟合与欠拟合；泛化能力；偏差方差权衡。